

인기 아이템의 지식으로 콜드 아이템을 깨우다

Recsys-09 루키비키자나

Tving 주제 2

팀장 - 김민지
팀원 1 - 이하운
팀원 2 - 하현진
팀원 3 - 김성윤
팀원 4 - 한상구

루키비키자나

인기 아이템의 지식으로 콜드 아이템을 깨우다

1. 개요

1. 프로젝트 타임라인 -4
2. 팀 구성 및 업무 분장 - 5
3. 문제 정의 - 6

2. 실험 설계 및 모델

1. 데이터셋 -8
2. EDA - 9
3. 해결 방향 - 11
4. 실험 설계 - 12
5. 문제 정의 - 15
6. Meta E - 16
7. MWUF - 17
8. CVAR - 18

3. 실험 결과

1. Warm-up #30 - 20
2. Early vs.Late - 21
3. Warm-up #60 - 22

4. 결론 및 고찰

1. 결과 요약 - 24
2. 자체 평가 의견 - 25
3. 추후 연구 방향 - 26

5. 부록

boostcamp ai tech

루키비키자나

개요

boostcamp^{ai}tech

01

01 프로젝트 타임라인



데이터 선정 및 문제 정의

EDA

연구 동향 리서치

실험 설계 및 Baseline

실험 및 결과 분석

보고서 작성

01 팀 구성 및 업무 분장



김민지

팀장

논문 리서치
EDA
가설 기반 실험 진행



이하윤

팀원

Baseline 코드 작성
Data preprocessing
가설 기반 실험 진행



하현진

팀원

모델 구현 및 수정
Feature engineering
Feature selection



김성운

팀원

Meta data 추가 수집
Data preprocessing
논문 정리



한상구


팀원

CF 모델 실험
Feature selection
논문 정리

01 문제 정의

Item Cold Start

추천을 위한 데이터 정보가 충분하지 않아서 해당 아이템들이
유저에게 추천되지 못하는 문제



루키비키자나

실험 설계 및 모델

boostcamp^{ai}tech

02

02 데이터셋

Steam Games Review Dataset

풍부한 **Item meta data**를 활용할 수 있는 데이터를 선정했습니다.

Data leakage가 발생할 수 있는 Features는 제거하였습니다.

#Interaction

14,529,074개

#User


680,812명

#Item

37,141개

Features	전처리	비고
User ID	Label encoding	유저의 id
Item ID	Label encoding	게임의 id
Hours	Log scaling	해당 리뷰를 남긴 시점의 플레이타임
Date_release	Minmax scaling	게임의 출시일
Price_original	Minmax scaling	게임의 기존 가격
Required_age	Binary encoding (16+ 이상 여부)	게임의 나이 제한
Metacritic_score	Minmax scaling	게임에 대한 평론가들의 점수
Category_embedding	Multi label encoding	게임 카테고리

02 EDA




상위 **2%**의 아이템의 Interaction이
전체 Interaction의 **80%**를 차지합니다.

소수의 인기 아이템이 대부분의
사용자 관심을 독점하는 형태를 의미합니다.

소수의 인기 아이템만 추천에 포함


모델	추천 아이템 개수
ALS	300
LightGCN	1,000
BERT4Rec	2,700
DeepFM	150



전체 아이템(36,000개) 대비 ALS(0.83%)와, LightGCN(2.78%),
BERT4Rec(7.5%), DeepFM(0.41%) 모두 **소수의 인기 아이템**만
추천하며, 전반적으로 **추천 범위가 제한적**입니다.

전체 아이템 중 **인터랙션이 많은** 아이템만 추천되고,
인터랙션이 적은 아이템은 추천되지 않는 구조

02 EDA



출시 후 시간이 지나도 Interaction이 적은 (2020년 이전) 아이템과
신규 출시되어 Interaction이 적은 (2020년 이후) 아이템의 비교 결과



Mann-Whitney U Test

 H_0 (귀무가설)

오래된 아이템과 신규 아이템의 평점
중앙값에는 **유의미한 차이가 없다.**

 H_1 (대립가설)

오래된 아이템과 신규 아이템의 평점
중앙값에는 **유의미한 차이가 존재한다.**

P-value($1.25e-168$) < 0.05 (귀무가설 기각)

오래된 아이템의 평점이 신규 아이템보다 **유의미하게 낮음**

-> 오래된 아이템을 추천하면 사용자 만족도가 낮아질 가능성이 높음


기존 연구는 **인터랙션이 적은 아이템**을 모두 **Cold Item**으로 정의한데 비해,
해당 프로젝트에서는 **신규 출시되어 인터랙션이 적은 아이템**에 집중할 필요가 있다고 판단하였습니다.

인기 아이템의 지식으로 콜드 아이템을 깨우다

적은 인터렉션과 해당 아이템의 부가 정보를 이용하여
신규 콜드 아이템의 Embedding을 개선하고자 합니다.

02 실험 설계

인기 아이템을 Pretrain으로 사용하고,
비인기 아이템 중 출시일이 2020년 이후인 아이템을
New Cold Item으로 정의합니다.




29p 참조

02 실험 설계

Backbone Model

DeepFM은 **유저/아이템 Context**를 이용한 이진분류 예측에 뛰어난 모델로 FM 파트와 MLP 파트로 나뉘어져 있습니다.



Pretrained 모델 성능 - 인기 아이템(leave one last)
AUC: [0.854], F1: [0.842]

선정 이유


Steam games review dataset은 활용할 수 있는 Item features가 많기에 데이터셋과 적합하다고 판단하였습니다.

기존에 실험했던 모델 중, Item ID Embedding 개선에 따라 성능 향상이 기대되므로 해당 모델을 선택하였습니다.

02 실험 설계


New Cold Item의 아이템 메타 데이터 및 소수의 리뷰를 활용하여 해당 아이템을 더 잘 표현하는 Embedding을 생성합니다.

Warm set당 10개의 Interaction 으로 구성.
최소 30개 이상의 데이터를 가진 아이템만 증분 학습 및 평가.



02 문제 정의

인기 아이템의 Interaction을 학습한 **Backbone** 모델은 새로운 아이템에 대한 ID Embedding을 알 수 없어 좋은 추천 결과를 생성하지 못합니다.




02 Meta Embedding

메타 러닝 접근 방식을 통해 Item meta data를 활용하여 ID Embedding을 학습하는 방법에 중점을 두어 모델에 적용합니다.

! 모델 한계점

모델 구조에 따른 item embedding 초기화 방법으로 인해 학습이 불안정




02 MWUF

New Item ID Embedding은 Old Item ID Embedding의 평균으로 초기화합니다.

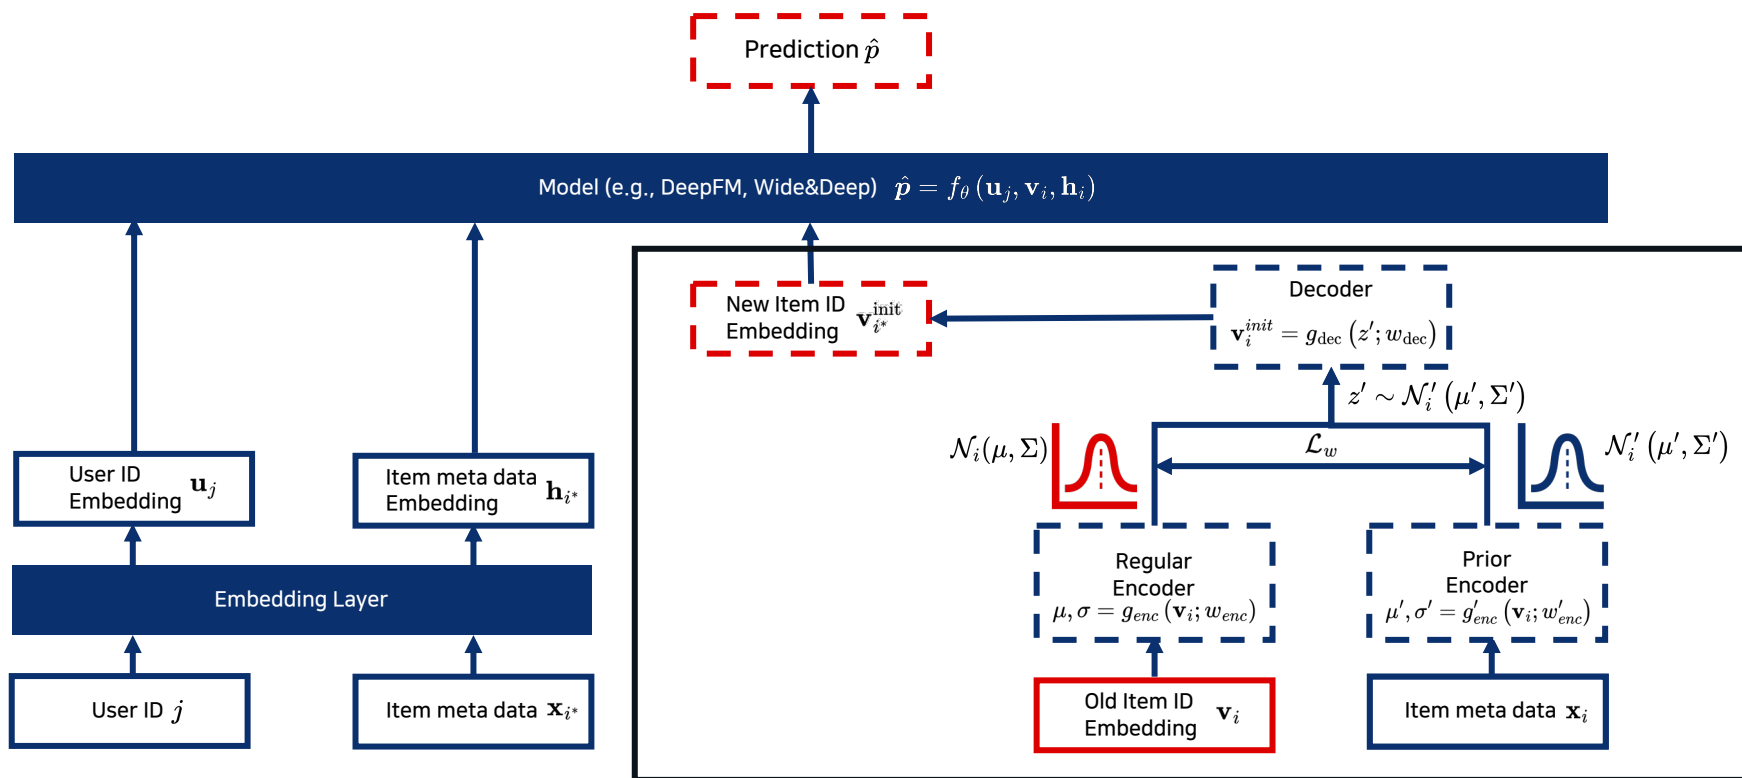
Meta Scaling Network는 각 아이템에 대해 스케일링 함수를 생성하여 콜드 ID Embedding을 변환하고, 이를 추천 모델에 더 적합한 **워밍업된 특징 공간**으로 매핑할 수 있도록 합니다.

또한, Meta Shifting Network는 노이즈가 포함된 Embedding으로부터 **안정적인 Embedding**을 생성할 수 있는 쉬프팅 함수를 학습합니다.



02 CVAR

CVAR은 오토인코더(autoencoder)의 잠재 공간(latent space)에서 $\mathbf{v}_i$ 와 $\mathbf{x}_i$ 의 잠재 표현을 정렬(alignment)하는 방식을 채택합니다. 신규 아이템 메타 데이터를 활용해, 개선된 아이템 ID Embedding을 생성하여 기존의 충분히 학습되지 않은 Embedding을 대체합니다.




루키비키자나

실험 결과

boostcamp^{ai}tech

03


03 Interaction Warm-up - #30



AUC

모델	Score 1	Score 4	증감율
Base	0.7775	0.7958	+2.35%
CVAR	0.7775	0.8106	+4.27%

Base 대비 CVAR에서 0.7958->
0.8106으로 1.86% 성능 향상




F1 score


모델	Score 1	Score 4	증감율
Base	0.8010	0.8119	+1.36%
CVAR	0.7884	0.8417	+6.75%

Base 대비 CVAR에서 0.8119->
0.8417으로 3.67% 성능 향상


03 Interaction Warm up – Early vs. Late



Base



MWUF



CVAR

Early Interaction

초기 0~30번째 Interaction

Late interaction

초반 31~60번째 Interaction

긍정적 평가 비율

Early

84.5%

Late

81.9%


test

81.1%

초기 데이터가 지나치게 긍정적으로 치우쳐 있을 가능성을 발견하였으며,
이는 학습을 불안정하게 만들 수 있습니다.

03 Interaction Warm up – #60

DeepFM의 60개 Warm-up에서의 성능을
CVAR은 20개 Warm-up만으로 달성하였습니다.



CVAR의 성능 향상율이 매우 뛰어남

적은 Interaction으로
빠르게 Warm-up이 가능합니다.

루키비키자나

결론 및 고찰

boostcamp^{ai}tech

04

04 결과 요약



Embedding 개선 방법을 통해 Item cold start 해결

- 30개 Interaction으로 warm-up 시 **AUC 1.86% 개선.**
(base 0.7958 -> CVAR 0.8106)
- Embedding initialization + Warm up 과정을 통해 **적은 Interaction**을 반영해서 개선합니다.



Early Interaction 보다 Late Interaction이 안정적

- 초기 데이터에는 **노이즈**가 있어 학습을 불안정하게 만들 수 있습니다.
(Novelty effect, 게임사 충성 고객 등)
- **충분한 Interaction**이 있다면 **학습에서 제외**하거나 **가중치를 조절**하는 등 여러 방향을 고려할 필요가 있습니다.



CVAR에서 1/3 Interaction으로 Base와 동일 성능 달성

- **Base**는 **60개** Interaction이 필요한 성능을 **CVAR**은 **20개** Interaction으로 달성 가능합니다.

CVAR은 노이즈가 섞인 데이터에서도 본질적인 정보를 복원해내어
콜드 아이템의 본질적인 특성을 효과적으로 학습하고 더욱 정교한 추천이 가능합니다.

04 자체 평가 의견



개선 방향 Scoping

기존 연구는 **Item Cold Start**와 **Popularity bias** 문제가 혼재되어 있어 신규 아이템의 추천 성능 향상을 정확히 확인하기 위해 **Dataset split** 방법을 개선하여 실험을 진행하였습니다.



Dataset 개선

Steam dataset에서 학습에 도움이 될 수 있는 데이터들을 추가 수집하고 해당 **Feature**의 특성을 분석, 전처리하여 모델의 입력으로 활용, 성능 개선을 이루었습니다.



Cold Start 문제 정의

문제 정의 과정에서 예상보다 많은 시간이 소요되어 아쉬움이 남지만, 이를 통해 **연구 목표와 접근 방식**을 더욱 정교하게 다듬을 수 있었습니다.



논리적 실험 과정

논리에 기반한 **의사 결정** 과정을 통해 문제 정의 및 문제 해결 과정을 거침으로서 새로운 방법론을 적용하는 과정에서 발생하는 문제들을 해결하고 **결과의 유의미함을 증명**할 수 있었습니다.

04 추후 연구 방향

추후 연구 방향

01

Backbone Model

현재 실험에서는 Backbone Model로 DeepFM을 사용하였으나, 향후 연구에서는 Item ID Embedding을 사용하는 다양한 모델에 적용 및 실험이 가능합니다.

02

User Cold Start

User meta data가 충분한 다른 데이터셋에 해당 방법론을 적용하여 User cold start 에서 적용하는 방향으로 확장 가능합니다.

End of Document

Thank You.

루키비키자나

부록

boostcamp^{ai}tech

05

Warm Up Cold-start Advertisements: Improving CTR Predictions via Learning to Learn ID Embeddings.

In SIGIR'19: The 42nd International ACM SIGIR Conference on Research & Development in Information Retrieval, July 21-25, 2019, Paris, France. ACM, New York, NY, USA, 10 pages.
<https://doi.org/10.1145/3331184.3331268>

Yongchun Zhu , Ruobing Xie , Fuzhen Zhuang, Kaikai Ge , Ying Sun , Xu Zhang, and Leyu Lin and Juan Cao . 2021.

Learning to Warm Up Cold Item Embeddings for Cold-start Recommendation with Meta Scaling and Shifting Networks.

In Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '21), July 11-15, 2021, Virtual Event, Canada. ACM, New York, NY, USA, 10 pages.
<https://doi.org/10.1145/3404835.3462843>


Xu Zhao, Yi Ren, Ying Du, Shenzheng Zhang, and Nian Wang. 2022. **Improving Item Cold-start**

Recommendation via Model-agnostic Conditional Variational Autoencoder.

In Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR'22), July 11-15, 2022, Madrid, Spain. ACM, New York, NY, USA, 6 pages.
<https://doi.org/10.1145/3477495.3531902>

05 상세 실험 설계

평균 Interaction 개수



New Cold & Old Cold

인기 아이템

5,126개
(Interaction 개수 300개 이상)

비인기 아이템

12,519 개
(Interaction 개수 30개 이상) - Holdout 가능

New Cold Item

4,168개
(2020 이후 출시 & 30개 이상 Interaction)

Old Cold Item

8,351개
(2020 이전 출시 & 30개 이상 Interaction)

Interaction Warm-up - #30

Pretrain Data

5,126개
(리뷰 개수 기준 정렬 상위 약 15%)

Warm-a, b, c & Holdout

4,168개
(2020 이후 출시 & 30개 이상 Interaction)

최종 AUC/F1은 CVAR과 베이스라인
간의 paired t-test 결과
 $p(4.93e-8, 3.98e-10) \leq 0.05$,
10회 반복 실험 평균 결과 기준

Interaction Warm-up - #60

Pretrain Data

5,126개
(리뷰 개수 기준 정렬 상위 약 15%)

Warm-a, b, c, d, e, f & Holdout

2,842개
(2020 이후 출시 & 60개 이상 Interaction)

05 상세 실험 설계

Interaction Warm-up - #10

Pretrain Data

5,126개

(Interaction 개수 300개 이상)

New Cold Item & Holdout

9,554개

(2020 이후 출시 & 10개 이상 Interaction)

base/CVAR 향상율

AUC: 0.7946 → 0.8082
(+1.71% 향상)

F1: 0.7986 → 0.8415
(+5.37% 향상)

일반화 성능 측정을 위해 추가 실험 진행한 결과